



北京大学
PEKING UNIVERSITY

School of Mechanics and
Engineering Science (MES)
力学与工程科学学院

计算方法 (00330050)

第 12 讲 数据拟合与函数逼近 (问题简介, 最小二乘法)

袁子峰 长聘副教授

北京大学 应用物理与技术研究中心
北京大学 力学与工程科学学院 科学计算与工程智能系

2026 年 4 月 28 日 (周二, 7-8 节课)



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 在科学实验或者统计研究中，人们常常需要从一组测定的数据

$$(x_i, y_i), i = 1, 2, \dots, n$$


获得自变量 x 与因变量 y 的一个**近似**解析表达式

$$y = \varphi(x).$$

- 一般并不要求近似函数过数据点；只要求能反映出数据点的基本趋势。




例题 12.1 对于下图中的数据点，多项式插值给出如下结果：





与之对应的，基于最小二乘法的线性回归给出给出如下结果：





问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 对于向量 $\boldsymbol{x} \in \mathbb{R}^n$, 其各种范数定义为

$$\begin{aligned} \text{1-范数} & : \quad \|\boldsymbol{x}\|_1 \equiv \sum_{i=1}^n |x_i| \\ \text{2-范数} & : \quad \|\boldsymbol{x}\|_2 \equiv \left(\sum_{i=1}^n x_i^2 \right)^{1/2} \\ \infty\text{-范数} & : \quad \|\boldsymbol{x}\|_\infty \equiv \max_{1 \leq i \leq n} |x_i| \end{aligned} \tag{12.1}$$



- 令 $\boldsymbol{x} \in \mathbb{R}^n$, $f: \mathbb{R}^n \mapsto \mathbb{R}$, f 对 $\boldsymbol{x}$ 的导数定义为

$$\frac{\partial f}{\partial \boldsymbol{x}} = \left[\frac{\partial f}{\partial x_1} \quad \frac{\partial f}{\partial x_2} \quad \cdots \quad \frac{\partial f}{\partial x_n} \right] \quad (12.2)$$

是一个行向量。



- 令 $\boldsymbol{x} \in \mathbb{R}^n$, 对于向量值函数 $f: \mathbb{R}^n \mapsto \mathbb{R}^m$ 定义为

$$\boldsymbol{f}(\boldsymbol{x}) = \begin{bmatrix} f_1(\boldsymbol{x}) & f_2(\boldsymbol{x}) & \cdots & f_m(\boldsymbol{x}) \end{bmatrix}^T \quad (12.3)$$

f 对 $\boldsymbol{x}$ 的导数为 $m \times n$ 矩阵:

$$\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix} \quad (12.4)$$



- 例如, 对于列向量 $\mathbf{u}, \mathbf{x} \in \mathbb{R}^n$,

$$\frac{\partial(\mathbf{u}^T \mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} u_1 & u_2 & \cdots & u_n \end{bmatrix} = \mathbf{u}^T \quad (12.5)$$

- 例如,

$$\frac{\partial(\mathbf{x}^T \mathbf{x})}{\partial \mathbf{x}} = 2 \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} = 2\mathbf{x}^T \quad (12.6)$$



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



定义 12.1 对于一个一元函数 $f(x)$ 在点 $x = a$ 的邻域有定义。如果存在 $\varepsilon > 0$, 使得

$$f(x) \geq f(a), \quad \forall |x - a| < \varepsilon \quad (12.7)$$

成立, 则称 $f(x)$ 在 $x = a$ 处取极小值。

一元函数的极值问题



- 如果 $f(x)$ 在 $x = a$ 的邻域内**可微**，则根据 TAYLOR 展开，我们有

$$f(a+h) - f(a) = h \left. \frac{df(x)}{dx} \right|_{x=a} + \frac{h^2}{2} \left. \frac{d^2f(x)}{dx^2} \right|_{x=a} + o(h^2) \quad (12.8)$$

- 若 $f(x)$ 在 $x = a$ 处取极小值，则必然有

$$\left. \frac{df(x)}{dx} \right|_{x=a} = 0 \quad (12.9)$$



证明: 如果 $f(x)$ 在 $x = a$ 处取极小值, 且

$$\left. \frac{df(x)}{dx} \right|_{x=a} \neq 0 \quad (12.10)$$

则我们可以定义

$$h = -\varepsilon \left. \frac{df(x)}{dx} \right|_{x=a} \quad (12.11)$$

这里 $\varepsilon > 0$ 是个极小的正数。



证明 (续.): 代入 TAYLOR 展开, 得到:

$$\begin{aligned} f(a+h) - f(a) &= h \left. \frac{df(x)}{dx} \right|_{x=a} + o(h) \\ &= -\varepsilon \left[\left. \frac{df(x)}{dx} \right|_{x=a} \right]^2 + o(h) \end{aligned} \tag{12.12}$$

与极小值假设矛盾。

一元函数的极值问题



- 将 **式. (12.9)** 代入 TAYLOR 展开, 得到:

$$f(a+h) - f(a) = \frac{h^2}{2} \left. \frac{d^2 f(x)}{dx^2} \right|_{x=a} + o(h^2) \quad (12.13)$$

因此, 当

$$\begin{cases} \left. \frac{df(x)}{dx} \right|_{x=a} = 0 \\ \left. \frac{d^2 f(x)}{dx^2} \right|_{x=a} > 0 \end{cases} \quad (12.14)$$

$f(x)$ 在 $x = a$ 处取极小值。

一元函数的极值问题



- 当

$$\begin{cases} \left. \frac{df(x)}{dx} \right|_{x=a} = 0 \\ \left. \frac{d^2f(x)}{dx^2} \right|_{x=a} < 0 \end{cases} \quad (12.15)$$

$f(x)$ 在 $x = a$ 处取极大值。



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



定义 12.2 对于一个多元函数 $f(x)$ 在点 $x = a$ 的邻域有定义。如果存在 $\varepsilon > 0$, 使得

$$f(x) \geq f(a), \quad \forall \|x - a\| < \varepsilon \quad (12.16)$$

成立, 则称 $f(x)$ 在 $x = a$ 处取极小值。这里 $\|\cdot\|$ 表示**向量范数**。



- 类似地, 假设 $f(\mathbf{x})$ 在点 $\mathbf{x} = \mathbf{a}$ 的邻域内可微, 我们要求当 $f(\mathbf{x})$ 在 $\mathbf{x} = \mathbf{a}$ 处取极小值时, $\mathbf{a}$ 是 $f(\mathbf{x})$ 的**驻点**, 即

$$\left. \frac{\partial f(\mathbf{x})}{\partial x_i} \right|_{\mathbf{x}=\mathbf{a}} = 0, \quad i = 1, 2, \dots, n \quad (12.17)$$

- 此时, $f(\mathbf{x})$ 在点 $\mathbf{x} = \mathbf{a}$ 的邻域内的 TAYLOR 展开表示为

$$f(\mathbf{a} + \mathbf{h}) - f(\mathbf{a}) = \frac{1}{2} \sum_{i,j=1}^n \left. \frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \right|_{\mathbf{x}=\mathbf{a}} h_i h_j + o(\|\mathbf{h}\|^2) \quad (12.18)$$



- 我们定义 HESSIAN 矩阵:

$$\mathbf{A} = [a_{ij}] \equiv \left[\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \right]_{\mathbf{x}=\mathbf{a}} \quad (12.19)$$

- 于是邻域内的 TAYLOR 展开简化为**二次型**:

$$f(\mathbf{a} + \mathbf{h}) - f(\mathbf{a}) = \frac{1}{2} \mathbf{h}^T \mathbf{A} \mathbf{h} + o(\|\mathbf{h}\|^2) \quad (12.20)$$



- 因此，我们得到多元函数的极值判定法则。如果

$$\left\{ \begin{array}{l} \frac{\partial f(\mathbf{x})}{\partial x_i} \Big|_{\mathbf{x}=\mathbf{a}} = 0, \quad i = 1, 2, \dots, n \\ \text{HESSIAN 矩阵 } \mathbf{A} \text{ 为正定矩阵} \end{array} \right. \quad (12.21)$$

则 $f(\mathbf{x})$ 在 $\mathbf{x} = \mathbf{a}$ 处取极小值。



- 反之, 如果

$$\left\{ \begin{array}{l} \frac{\partial f(\mathbf{x})}{\partial x_i} \Big|_{\mathbf{x}=\mathbf{a}} = 0, \quad i = 1, 2, \dots, n \\ \text{HESSIAN 矩阵 } \mathbf{A} \text{ 为负定矩阵} \end{array} \right. \quad (12.22)$$

则 $f(\mathbf{x})$ 在 $\mathbf{x} = \mathbf{a}$ 处取极大值。



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 回顾**多项式插值**问题:

给出 $n + 1$ 个点上的函数表

x	x_0	x_1	$\cdots$	x_n
y	y_0	y_1	$\cdots$	y_n

要构造一个插值多项式 $\varphi_n(x)$ 满足

▷ $\varphi_n(x)$ 是次数不超过 n 的多项式;

▷ $\varphi_n(x_j) = f(x_j) = y_j, \quad j = 0, 1, \cdots, n。$



- 当数据点数量较多时，高次的插值多项式很难给出直观的演化规律。



- 当数据点数量较多时，高次的插值多项式很难给出直观的演化规律。
- 可以根据数据的特征定义由某些简单函数组成的函数空间 $\mathcal{H}$ 。然后寻求函数 $\varphi(x) \in \mathcal{H}$ 来近似数据，从而获取更为直观的内在函数关系。



- 当数据点数量较多时，高次的插值多项式很难给出直观的演化规律。
- 可以根据数据的特征定义由某些简单函数组成的函数空间 $\mathcal{H}$ 。然后寻求函数 $\varphi(x) \in \mathcal{H}$ 来近似数据，从而获取更为直观的内在函数关系。
- 一般来说，此时的 $\varphi(x)$ 将无法严格通过每一个数据点；也就是在每个 x_i 处，产生了**残差**：

$$\delta_i = y_i - \varphi(x_i) \quad (12.23)$$

- 从而，数据拟合问题可以描述为：

寻找**最佳的** $\varphi(x) \in \mathcal{H}$ 拟合给定的数据点，从而使得残差"最小"。



- 考虑到数组形式的残差无法直接比大小，因此可以定义如下准则：
 - ▷ 最小化残差的绝对值之和 $\sum_i |\delta_i|$ (**最小一乘法**);
 - ▷ 最小化残差的最大绝对值 $\max_i |\delta_i|$ (**最佳一致逼近**); 或者
 - ▷ 最小化残差的平方和 $\sum_i \delta_i^2$ (**最小二乘法**)。



- 最小二乘法计算方便，因此常在实践中采用。具体地，**数据拟合的最小二乘问题**描述如下：

给定数据组 $(x_i, y_i), i = 1, 2, \dots, n$ ，根据函数空间 $\mathcal{H}$ ，寻求 $\varphi \in \mathcal{H}$ ，使得

$$\sum_{i=1}^n \delta_i^2 = \sum_{i=1}^n (y_i - \varphi(x_i))^2 = \min_{\psi \in \mathcal{H}} \sum_{i=1}^n (y_i - \psi(x_i))^2 \quad (12.24)$$



- 实践中, 可以将 $\mathcal{H}$ 定义为低次多项式函数集。于是就有了**多项式拟合**问题:

给定数据组 $(x_i, y_i), i = 1, 2, \dots, n$, 寻求

$$P_m(x) = a_0 + a_1x + \dots + a_mx^m, \quad m < n - 1 \quad (12.25)$$

(当 $m = n - 1$ 时退化为插值问题)

使得

$$\sum_{i=1}^n \delta_i^2 = \sum_{i=1}^n (y_i - P_m(x_i))^2 = F(a_0, a_1, \dots, a_m) \quad (12.26)$$

为最小。



- 多元函数极值需要计算其驻点，于是得到方程组

$$\frac{\partial F}{\partial a_j} = 0, \quad j = 0, 1, \dots, m \quad (12.27)$$

展开得到:

$$-2 \sum_{i=1}^n \left[y_i - \sum_{k=0}^m a_k x_i^k \right] x_i^j = 0, \quad j = 0, 1, \dots, m \quad (12.28)$$



- 写成矩阵形式:

$$\begin{bmatrix} n & \sum_{i=1}^n x_i & \cdots & \sum_{i=1}^n x_i^m \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \cdots & \sum_{i=1}^n x_i^{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^m & \sum_{i=1}^n x_i^{m+1} & \cdots & \sum_{i=1}^n x_i^{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_i \\ \vdots \\ \sum_{i=1}^n y_i x_i^m \end{bmatrix} \quad (12.29)$$



- 也可以从线性超定方程组 ($m + 1$ 个未知数, n 个方程) 的角度理解:

$$\begin{bmatrix} 1 & x_1 & \cdots & x_1^m \\ 1 & x_2 & \cdots & x_2^m \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_1^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \Rightarrow \quad \mathbf{A} \mathbf{a} = \mathbf{b} \quad (12.30)$$



- 残差的平方和写成

$$F \equiv \|\mathbf{A}\mathbf{a} - \mathbf{b}\|^2 = (\mathbf{A}\mathbf{a} - \mathbf{b})^T(\mathbf{A}\mathbf{a} - \mathbf{b}) \quad (12.31)$$

- 多元函数极值需要计算其驻点，于是得到方程组

$$\frac{\partial F}{\partial \mathbf{a}} = 0 \quad (12.32)$$

上式等价于

$$\mathbf{A}^T \mathbf{A} \mathbf{a} = \mathbf{A}^T \mathbf{b} \quad (12.33)$$



- 可以验证:

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} n & \sum_{i=1}^n x_i & \cdots & \sum_{i=1}^n x_i^m \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \cdots & \sum_{i=1}^n x_i^{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^m & \sum_{i=1}^n x_i^{m+1} & \cdots & \sum_{i=1}^n x_i^{2m} \end{bmatrix} \quad (12.34)$$

而这个系数矩阵的问题在于**病态**性质，在多项式阶数较大的时候，计算误差会很大。


- 多项式阶数低：欠拟合；多项式阶数高：过拟合。



- 当 $m = 1$ 时, 我们可以将超定方程组改写成

$$\begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} a_0 + \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} a_1 = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \Rightarrow \quad \mathbf{A}_1 a_0 + \mathbf{A}_2 a_1 = \mathbf{b} \quad (12.35)$$

- 从几何的视角，就是寻求系数 a_0, a_1 ，使得 $\mathbb{R}^n$ 中的向量 b 能写成 A_1 与 A_2 的线性组合。
- 然而，如右图所示， b 未必落在由向量 A_1 与 A_2 张成的超平面 S 之中；因此，只能退而求其次，寻求系数 a_0, a_1 表示 b 在超平面 S 中的投影 $b_{\square}$ 。从而要求



$$\min_{a_0, a_1} \|r\|^2 = \min_{a_0, a_1} \|A_1 a_0 + A_2 a_1 - b\|^2 \quad (12.36)$$



- 从几何的角度, $\min_{a_0, a_1} \|r\|^2$ 等价于

$$\begin{cases} r \perp A_1 \\ r \perp A_2 \end{cases}, \quad \Rightarrow \quad \begin{cases} r^T A_1 = (A_1 a_0 + A_2 a_1 - b)^T A_1 = 0 \\ r^T A_2 = (A_1 a_0 + A_2 a_1 - b)^T A_2 = 0 \end{cases} \quad (12.37)$$

整理得到与之前一样的方程组形式。



例题 12.3 对于数据表

x_i	1	2	3	4	5
y_i	0.6	2.4	3.5	4.8	5.7

使用最小二乘法，确定最佳的拟合函数

$$y = a_0 + a_1 x$$

(例12.3-1)



解：计算如下数据

x_i	y_i	x_i^2	$x_i y_i$
1	0.6	1	0.6
2	2.4	4	4.8
3	3.5	9	10.5
4	4.8	16	19.2
5	5.7	25	28.5
15	17.0	55	63.6



解: (续) 得到系数

$$a_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} = \frac{5 \times 63.6 - 15 \times 17}{5 \times 55 - 225} = 1.26 \quad (\text{例12.3-2})$$

并继而获得

$$a_0 = \frac{1}{n} \sum_{i=1}^n y_i - \frac{a_1}{n} \sum_{i=1}^n x_i = -0.38 \quad (\text{例12.3-3})$$



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 如果数据点 $(x_i, y_i), i = 1, 2, \dots, n$ 近似满足指数函数, 则可以考虑采用

$$y = b e^{ax} \quad (12.38)$$

去拟合数据, 其中 a, b 为待定常数。

- 如果直接套用最小二乘法, 则需要求解非线性方程组:

$$\begin{aligned} \frac{\partial}{\partial a} \sum_{i=1}^n (y_i - b e^{ax_i})^2 &= 0 \\ \frac{\partial}{\partial b} \sum_{i=1}^n (y_i - b e^{ax_i})^2 &= 0 \end{aligned} \quad (12.39)$$



- 一个更为简便的方法:

$$\begin{aligned} y = b e^{ax} &\Rightarrow \ln y = ax + \ln b \\ (x_i, y_i) &\Rightarrow (x_i, \ln y_i) \end{aligned} \quad (12.40)$$

退化为一项多项式拟合问题。



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 如果数据点 $(x_i, y_i), i = 1, 2, \dots, n$ 近似满足分式线性函数

$$y = \frac{1}{ax + b} \quad (12.41)$$

其中 a, b 为待定常数。

- 同样可以采用如下变换

$$\begin{aligned} y = \frac{1}{ax + b} &\Rightarrow \frac{1}{y} = ax + b \\ (x_i, y_i) &\Rightarrow (x_i, 1/y_i) \end{aligned} \quad (12.42)$$



- 如果数据点 $(x_i, y_i), i = 1, 2, \dots, n$ 近似满足分式线性函数

$$y = \frac{x}{ax + b} \quad (12.43)$$

其中 a, b 为待定常数。

- 同样可以采用如下变换

$$\begin{aligned} y = \frac{x}{ax + b} &\Rightarrow \frac{1}{y} = a + b \cdot \frac{1}{x} \\ (x_i, y_i) &\Rightarrow (1/x_i, 1/y_i) \end{aligned} \quad (12.44)$$



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 对于更为一般的情形, 假设数据 $(x_i, y_i), i = 1, 2, \dots, n$ 可以通过一组**线性无关**的函数 $\varphi_k(x), k = 0, 1, \dots, m$ 近似表示。
- 设近似函数 $\varphi(x)$ 表示为

$$\varphi(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \dots + a_m\varphi_m(x) \quad (12.45)$$

我们寻求系数 $a_k, k = 0, 1, \dots, m$ 使得

$$\sum_{i=1}^n \omega_i [y_i - \varphi(x_i)]^2 = \sum_{i=1}^n \omega_i \left[y_i - \sum_{k=0}^m a_k \varphi_k(x_i) \right]^2 \quad (12.46)$$

取最小值, 其中 $\omega_i > 0, i = 1, 2, \dots, n$ 为权系数。



- 例如, 如果 $\varphi_k = x^k, k = 0, 1, \dots, m$, 那么就是采用不超过 k 次的多项式函数进行近似。
- 对于极值问题, 系数 $a_k, k = 0, 1, \dots, m$ 通过下列方程组计算:

$$\frac{\partial}{\partial a_j} \sum_{i=1}^n \omega_i \left[y_i - \sum_{k=0}^m a_k \varphi_k(x_i) \right]^2 = 0, \quad j = 0, 1, \dots, m \quad (12.47)$$

即

$$\sum_{i=1}^n \omega_i \left[y_i - \sum_{k=0}^m a_k \varphi_k(x_i) \right] \varphi_j(x_i) = 0, \quad j = 0, 1, \dots, m \quad (12.48)$$



• 定义

$$(\varphi_k, \varphi_j) = \sum_{i=1}^n \omega_i \varphi_k(x_i) \varphi_j(x_i), \quad (y, \varphi_j) = \sum_{i=1}^n \omega_i y_i \varphi_j(x_i) \quad (12.49)$$

于是方程组可以写成如下矩阵形式:

$$\underbrace{\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_m) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_m) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_m, \varphi_0) & (\varphi_m, \varphi_1) & \cdots & (\varphi_m, \varphi_m) \end{bmatrix}}_{\equiv \mathbf{A}} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} (y, \varphi_0) \\ (y, \varphi_1) \\ \vdots \\ (y, \varphi_m) \end{bmatrix} \quad (12.50)$$



- 然而，这个方程组的系数矩阵 $\mathbf{A}$ 一般是病态的，当 m 较大时病态更为严重。
- 因此，如果 $\varphi_k(x)$ 满足

$$(\varphi_k, \varphi_k) = \sum_{i=1}^n \omega_i \varphi_k^2(x_i) > 0, \quad k = 0, 1, \dots, m \quad (12.51)$$

$$(\varphi_k, \varphi_j) = 0, \quad k \neq j$$

这样 $\mathbf{A}$ 退化为对角矩阵，于是 a_k 可以直接求得：

$$a_k = \frac{(y, \varphi_k)}{(\varphi_k, \varphi_k)} = \frac{\sum_{i=1}^n \omega_i y_i \varphi_k(x_i)}{\sum_{i=1}^n \omega_i \varphi_k^2(x_i)}, \quad k = 0, 1, \dots, m \quad (12.52)$$



定义 12.3 称满足 **式. (12.51)** 的函数组 $\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x)$ 为以 $\{\omega_i\}, (i = 1, 2, \dots, n)$ 为权, 关于点集 $\{x_1, x_2, \dots, x_n\}$ 的**正交函数族**。

- 例如, 可以根据给定的权系数 $\{\omega_i\}, (i = 1, 2, \dots, n)$ 和点集 $\{x_1, x_2, \dots, x_n\}$, 采用递推法构造**正交多项式函数族**:

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_1(x) = x - \alpha_1 \\ \varphi_k(x) = (x - \alpha_k)\varphi_{k-1}(x) - \beta_k\varphi_{k-2}(x), \quad k = 2, 3, \dots, m \end{cases} \quad (12.53)$$



- 其中

$$\begin{aligned}\alpha_k &= \frac{(x\varphi_{k-1}, \varphi_{k-1})}{(\varphi_{k-1}, \varphi_{k-1})}, & k &= 1, 2, \dots, m \\ \beta_k &= \frac{(\varphi_{k-1}, \varphi_{k-1})}{(\varphi_{k-2}, \varphi_{k-2})}, & k &= 2, 3, \dots, m\end{aligned}\tag{12.54}$$



问题简介

数学准备

向量范数与对向量的导数

一元函数的极值问题

多元函数的极值问题

数据拟合的最小二乘法

多项式拟合

指数拟合

分式线性拟合

一般形式

超越最小二乘法的问题



- 给定一组测定的数据

$$(x_k, y_k) = (k h, y_k), \quad k = 1, 2, \dots, n$$

$h > 0$ 为数据间隔。



- 给定一组测定的数据

$$(x_k, y_k) = (k h, y_k), \quad k = 1, 2, \dots, n$$

$h > 0$ 为数据间隔。

- 如何通过如下函数

$$y(x) = \sum_{p=1}^m a_p \exp\{\lambda_p x\} \quad (12.55)$$

对数据进行拟合？其中 $m > 1$ 、 a_p 以及 λ_p 均为待定实参数（实际上 λ_p 可以是复数），并一般假定 $n \gg 2m$ 。



- 定义 $\mu_p \equiv \exp\{\lambda_p h\}$, $p = 1, 2, \dots, m$, 于是:

$$y(x_k) = \sum_{p=1}^m a_p \exp\{\lambda_p k h\} = \sum_{p=1}^m a_p \mu_p^k \quad (12.56)$$

- 构造以 μ_p , $p = 1, 2, \dots, m$ 为根的多项式:

$$c_m \mu^m + c_{m-1} \mu^{m-1} + \dots + c_1 \mu + c_0 = 0, \rightarrow \sum_{q=0}^m c_q \mu_p^q = 0 \quad (12.57)$$

可以得到, 对 $k = 1, 2, \dots, n - m$, 有如下恒等式

$$\sum_{q=0}^m c_q y(x_{k+q}) = \sum_{q=0}^m c_q \sum_{p=1}^m a_p \mu_p^{k+q} = \sum_{p=1}^m a_p \mu_p^k \sum_{q=0}^m c_q \mu_p^q = 0 \quad (12.58)$$



- 针对原始数据 $(k h, y_k)$, 可以得到如下关于 c_q , $q = 0, 1, \dots, m-1$ (这里可以令 $c_m = 1$) 的超定方程组:

$$\begin{bmatrix} y_m & y_{m-1} & \cdots & y_1 \\ y_{m+1} & y_m & \cdots & y_2 \\ \vdots & \vdots & \ddots & \vdots \\ y_{n-1} & y_{n-2} & \cdots & y_{n-m} \end{bmatrix} \begin{bmatrix} c_{m-1} \\ c_{m-2} \\ \vdots \\ c_0 \end{bmatrix} = - \begin{bmatrix} y_{m+1} \\ y_{m+2} \\ \vdots \\ y_n \end{bmatrix} \quad (12.59)$$

- 通过最小二乘法得到最佳系数 c_q , $q = 0, 1, \dots, m-1$ 后, 可以进而求解 μ_p , $p = 1, 2, \dots, m$, 即 λ_p ; 最后再通过最小二乘法得到系数 a_p 。



- 拟合函数

$$y(x) = \sum_{p=1}^m a_p \exp\{\lambda_p x\}$$

实际上是常系数常微分方程的一个通解：

$$\left[A_m \frac{d^m}{dx^m} + A_{m-1} \frac{d^{m-1}}{dx^{m-1}} + \dots A_1 \frac{d}{dx} + A_0 \right] y(x) = 0 \quad (12.60)$$

- 上述过程实现了**从数据学习（一个固定形式的）微分方程**这一过程。



- 但问题在于我们是否提供了一个足够准确的微分方程形式？例如我们也可以假定数据服从如下非线性微分方程形式（但阶数只有 1 阶）：

$$\frac{dy}{dx} = B_0 + B_1 y + B_2 y^2 + \cdots + B_m y^m \quad (12.61)$$



- 但问题在于我们是否提供了一个足够准确的微分方程形式？例如我们也可以假定数据服从如下非线性微分方程形式（但阶数只有 1 阶）：

$$\frac{dy}{dx} = B_0 + B_1 y + B_2 y^2 + \cdots + B_m y^m \quad (12.61)$$

- 例如经典的 Logistic 种群增长模型：

$$\frac{dP}{dt} = rP \left(1 - \frac{P}{K} \right) \quad (12.62)$$

其中 P 为种群数量， r 为一种内禀增长率， $K > 0$ 为环境最大容量。当 $P \ll K$ 时，种群数量呈现近似指数增长，但当 $P \rightarrow K$ 时增长率趋于 0。



- 以下介绍一种从数据中挖掘微分方程的方法——稀疏识别非线性动力学¹
SINDy (Sparse Identification of Nonlinear Dynamics)。
- 该方法需要预设一个候选函数库，例如

$$\Theta(y) = [1, y, y^2, y^3, \dots, y^M] \quad (12.63)$$

- 假设微分方程形式上写成

$$y' = \Theta(y) \xi \quad (12.64)$$

$\xi \in \mathbb{R}^M$ 是待定系数列向量。

¹ Brunton Steven L; Proctor Joshua L; Kutz J Nathan. Discovering governing equations from data by sparse identification of nonlinear dynamical systems.[J]. Proceedings of the National Academy of Sciences of the United States of America, 2016, 113(15):3932-7. DOI:10.1073/pnas.1517384113.



- 对微分方程两端积分，得到

$$y(x_{k+1}) - y(x_k) = \int_{x_k}^{x_{k+1}} \Theta(y(\chi)) \xi \, d\chi = \underbrace{\int_{x_k}^{x_{k+1}} \Theta(y(\chi)) \, d\chi}_{\text{数值积分章节}} \xi \quad (12.65)$$

- SINDy 法认为，尽管预设的函数库可以很庞大，但实际微分形式中只会出现较少的几项（即“稀疏识别”），因此我们可以引入 LASSO（Least Absolute Shrinkage and Selection Operator）：

$$\xi = \text{Arg min} \left\{ \underbrace{\|y' - \Theta\xi\|_2^2}_{\text{拟合误差}} + \underbrace{\lambda\|\xi\|_1}_{\text{惩罚项}} \right\} \quad (12.66)$$

课件版本说明



- **v1.0** 2022/05/11, 2021-22 学年计算方法课程讲义;
- **v2.0** 2022/12/24, 2022-23 学年计算方法课程讲义, 根据教材 **数值计算方法** 修改了部分内容。
- **v3.0** 2024/02/08, 2023-24 学年计算方法课程讲义。